

Práctica II

Aprendizaje NO Supervisado

Análisis de canciones de Spotify



Asignatura: Aprendizaje Automático I
Fecha de entrega: 30 de diciembre de 2025

Autores:
Mora Medina, Manuel Adrián
Plohod, Raul Matei

Índice General

1	Introducción	1
1.1	Alcance del Estudio	1
1.2	Contexto Musical: Los Géneros Esperados	1
2	Preprocesamiento de datos	3
2.1	Análisis de Variables Numéricas	3
2.1.1	Tratamiento de Asimetría (Skewness) y Outliers	3
2.2	Escalado de Datos	4
2.3	Selección de Características (Feature Selection)	4
3	Tarea I: Clustering Jerárquico	5
3.1	Tarea 1.1: Selección de Algoritmo y Métrica	5
3.1.1	Análisis de Distancias en Agglomerative Clustering	5
3.1.2	Análisis del Algoritmo BIRCH	6
3.1.3	Conclusión Tarea 1.1	6
3.2	Tarea 1.2: Análisis de Distribución y Profundidad	7
3.2.1	Análisis de Uniformidad	7
3.2.2	Conclusión Tarea 1.2	7
3.3	Tarea 1.3: Impacto de la Métrica en la Estructura	7
3.3.1	Análisis Comparativo	8
3.4	Tarea 1.4: Índices de Calidad y Selección de K	8
3.4.1	Análisis Comparativo de Métricas	8
3.4.2	Análisis Visual de Siluetas (Diagramas de Sierra)	9
3.5	Tarea 1.5: Perfilado de Clústeres y Elección Final	10
3.5.1	Análisis Visual de Centroides (Heatmaps)	10
3.5.2	Interpretación Semántica (Mapeo a Géneros)	10
3.5.3	Conclusión Final Tarea 1	11
4	Tarea II: Clustering Particional	12
5	Tarea 2: Algoritmos Particionales (K-Means)	12
5.1	Tarea 2.1: Preprocesado	12
5.2	Tarea 2.2 y 2.3: Selección del Número de Clústeres (K)	12
5.2.1	Decisión: Matemáticas vs. Negocio	12
5.3	Tarea 2.4: Interpretación de los Clústeres ($K = 8$)	13
5.4	Tarea 2.5: Comparativa Final (Particional vs Jerárquico)	14
6	Tarea III: Clustering de densidad	14
6.1	Tarea 3.1: Preprocesamiento para Densidad	14
6.2	Tarea 3.2: Selección de Parámetros (Eps y MinPts)	15
6.2.1	Estimación de MinPts	15
6.2.2	Estimación de Eps (K-Distance Plot)	15
6.3	Tarea 3.3: Evaluación de Calidad y Variación de Parámetros	16
6.3.1	Análisis de la Variación	16
6.3.2	Análisis de la Mejor Configuración ($\epsilon = 0,22$, $Min = 8$)	16
6.4	Tarea 3.4: Evaluación de Índices de Calidad	17

6.4.1	La Paradoja Calidad-Utilidad	17
6.4.2	Análisis Visual de Siluetas	17
6.5	Tarea 3.5: Elección del Número Óptimo y Perfilado	18
6.5.1	Análisis Comparativo de Perfiles	18
6.5.2	Interpretación Semántica (Modelo de 7 Clústers)	18
6.5.3	Conclusión Final	18

1. Introducción

El objetivo principal de esta práctica es agrupar **canciones de Spotify según su género** utilizando técnicas de Aprendizaje Automático. Al tratarse de un problema de *clustering* (aprendizaje no supervisado), **no disponemos de etiquetas predefinidas** que nos indiquen el género real de cada canción. Por tanto, nuestro reto consiste en descubrir la estructura subyacente de los datos para generar grupos (clústers) donde las canciones sean **lo más homogéneas posible entre sí** y lo más heterogéneas posible respecto a los otros grupos.

1.1. Alcance del Estudio

Para abordar este problema, el análisis se centrará en la implementación y comparativa exhaustiva de las tres familias de algoritmos fundamentales vistas en la asignatura:

- **Algoritmos Jerárquicos:** Para analizar la estructura taxonómica de los datos.
- **Algoritmos Particionales:** Específicamente K-Means, para buscar agrupaciones compactas.
- **Algoritmos de Densidad:** Específicamente DBSCAN, para detectar formas complejas y gestionar el ruido.

El proyecto se focaliza en la **optimización de hiperparámetros y el análisis profundo** de estos tres métodos, dejando fuera del alcance de esta memoria la exploración de otros algoritmos experimentales opcionales.




Figura 1: Esquema de Aprendizaje No Supervisado.

Seguiremos un flujo de trabajo estructurado: partiendo de un preprocesado robusto, pasaremos a la ejecución de los algoritmos, la evaluación mediante índices de calidad (Silueta, Calinski-Harabasz, Davies-Bouldin) y, finalmente, la interpretación semántica de los resultados.

1.2. Contexto Musical: Los Géneros Esperados

Aunque trabajamos sin etiquetas, contamos con conocimiento de dominio sobre los géneros que componen el dataset. Estas definiciones nos servirán de guía para validar si nuestros clústers tienen sentido musical:

Pop: Género mainstream centrado en melodías pegadizas, estructuras simples (generalmente estrofa–estribillo) y estribillos memorables. Suele orientarse a un público amplio y a la difusión en radio.

Rock: Estilo basado tradicionalmente en guitarras, bajo y batería. Puede variar desde sonidos suaves y melódicos hasta interpretaciones más intensas y agresivas.

Electronic / EDM: Estilos donde el sonido se produce mayoritariamente mediante sintetizadores. Vinculado a la música de baile y festivales, con énfasis en ritmos repetitivos.

Hip-Hop / Rap: Género centrado en la voz hablada o rapeada sobre una base rítmica, donde las letras son protagonistas.

Acoustic / Folk: Estilos que utilizan principalmente instrumentos acústicos (guitarra, voz) y percusiones suaves, con énfasis en la interpretación orgánica.

Classical: Música de tradición académica occidental (orquestas, solistas), caracterizada por estructuras formales elaboradas y gran dinámica.

...entre otros subgéneros posibles.

Partiendo de la hipótesis de que existen **al menos 6 estructuras diferenciadas**, nuestro objetivo es recuperar estos géneros mediante matemáticas y, si es posible, descubrir sub-géneros ocultos.



Figura 2: Representación visual de géneros musicales.

2. Preprocesamiento de datos

El objetivo de esta fase es preparar el dataset para los algoritmos de clustering. Comenzamos con 5040 registros. Tras un análisis preliminar de nulos, detectamos 275 filas con valores faltantes en todas las variables numéricas. Dado que representan un porcentaje bajo ($\approx 5\%$), procedemos a eliminarlas, quedándonos con **4765 registros útiles**.

2.1. Análisis de Variables Numéricas

Para comprender la distribución de los datos, analizamos los histogramas de las variables principales (Figura 3). A simple vista, observamos que la mayoría no siguen una distribución normal, presentando comportamientos bimodales (*acousticness*) o fuertes asimetrías (*liveness*, *speechiness*).




Figura 3: Distribución inicial de las variables numéricas.

2.1.1. Tratamiento de Asimetría (Skewness) y Outliers

Para decidir qué variables transformar, calculamos el *Skewness*. Definimos un semáforo de decisión: **Verde** ($-0,8 < Skew < 0,8$) donde no transformamos, y **Rojo** (fuera de rango) donde evaluamos transformaciones logarítmicas o cúbicas.

La Tabla 1 resume las decisiones tomadas. Destacamos tres casos especiales:

1. **Duration ms (Skew 21.8)**: Extremadamente asimétrica debido a outliers (canciones muy largas o audiolibros). Aplicamos **Logaritmo**, corrigiendo el skew a -0.52 (Verde).
2. **Loudness (Skew -2.06)**: Al contener valores negativos (dB), aplicamos **Raíz Cúbica**, corrigiendo el skew a -0.17 (Verde).

3. **Excepciones Semánticas (Speechiness, Instrumentalness, Liveness):** Aunque están en Rojo”, **NO las transformamos**. Según la documentación de Spotify, estos valores tienen significados funcionales (ej. *speechiness* > 0,66 indica Podcast). Aplicar logaritmos distorsionaría la separación natural entre ”Música” y ”Habla”.

Cuadro 1: Análisis de Asimetría y Decisiones de Transformación

Variable	Skew Original	Decisión	Acción / Resultado
Danceability	-0.67	Verde	Se mantiene original.
Tempo	0.29	Verde	Se mantiene original.
Energy	(Beta)	Verde	Se mantiene original.
Duration_ms	21.83	Rojo	Logaritmo → Skew -0.52.
Loudness	-2.06	Rojo	Raíz Cúbica → Skew -0.17.
Speechiness	3.32	Rojo*	Mantener (Criterio semántico).
Liveness	2.18	Rojo*	Mantener (Criterio semántico).
Instrumentalness	1.79	Rojo*	Mantener (Criterio semántico).

Las transformaciones efectivas se pueden observar en la Figura 4.




Figura 4: Variables corregidas tras aplicar transformaciones.

2.2. Escalado de Datos

Dado que la mayoría de nuestras variables no siguen una distribución normal (descartando así *StandardScaler*) y muchas ya se encuentran acotadas en el rango $[0, 1]$, optamos por utilizar **MinMaxScaler**. Esto normaliza todas las variables al rango $[0, 1]$ sin distorsionar la estructura de los datos que no son gaussianos, permitiendo que las distancias (Euclídea, etc.) sean justas entre atributos.

2.3. Selección de Características (Feature Selection)

Para finalizar el preprocesado, eliminamos variables que introducen ruido o redundancia:

- **Identificadores (track_name, artist_name):** Tienen una cardinalidad demasiado alta (2187 artistas) y no aportan información de “estilo” musical generalizable.
- **Variables Categóricas/Teóricas (key, time_signature):**
 - *Key (Tonalidad):* Es una variable cíclica (Do está cerca de Si), pero numérica en el dataset. La tonalidad no define el género (hay Rock y Pop en Do Mayor).
 - *Time Signature (Compás):* La inmensa mayoría es 4/4. Aporta varianza nula o ruido artificial.

- **Redundancia (loudness):** La matriz de correlación mostró un coeficiente de **0.81** entre `energy` y `loudness`. Para evitar colinealidad, eliminamos `loudness` (incluso tras su transformación) y conservamos `energy`, que no tenía outliers ni requirió transformación.

El dataset final, denominado `dataset_spotify_preprocesado`, contiene las variables numéricas escaladas y limpias, listo para la fase de clustering.

3. Tarea I: Clustering Jerárquico

Ahora se procederán a realizar las tareas.

3.1. Tarea 1.1: Selección de Algoritmo y Métrica

Nos piden: “Aplica al menos 2 algoritmos de *clustering* jerárquico probando y evaluando los efectos de la distancia utilizada.”

Hemos evaluado dos familias de algoritmos:

1. **Agglomerative Clustering (Bottom-Up):** Probando distancias Euclídea, Manhattan, Coseno y Chebyshev con enlaces Ward, Average y Complete.
2. **BIRCH (Top-Down):** Probando diferentes *thresholds* de ramificación.

Para evaluar la calidad, fijamos un $K = 14$ (suficiente para capturar los 6 géneros base más subgéneros) y realizamos una inspección cualitativa sobre 3 registros de control: dos canciones del mismo género (Pop) y una discordante (Rock) para verificar si el algoritmo las separaba correctamente.

3.1.1. Análisis de Distancias en Agglomerative Clustering

A continuación, resumimos el comportamiento de cada métrica tras analizar la coherencia de los clústeres generados y su capacidad para separar los registros de control.

1. Distancia Euclídea (Linkage: Ward) Fue la combinación más robusta. El método **Ward**, al minimizar la varianza intra-clúster, generó grupos compactos y equilibrados.

- **Prueba de Control:** Logró agrupar correctamente los dos registros de Pop en el mismo clúster y, lo más importante, **separó el registro de Rock en un clúster distinto**.
- **Calidad:** Las medias de los clústeres resultantes eran muy representativas de los atributos reales de las canciones (ver notebook para detalle de tablas).

2. Distancia Manhattan (Linkage: Complete) Ofreció resultados aceptables, situándose como la segunda mejor opción.

- **Comportamiento:** Similar a la Euclídea, logró separar la canción de Rock de las de Pop.
- **Deficiencias:** Falló ligeramente al caracterizar variables como `acousticness`, donde las medias del clúster no eran tan precisas como con Ward.

3. Distancia Coseno y Chebyshev (Descartadas) Ambas métricas mostraron un comportamiento deficiente, tendiendo a generar **macro-clústeres** que absorbían la mayoría de los datos.

- **Prueba de Control:** Ninguna de las dos logró separar la canción de Rock, asignándola al mismo grupo genérico que las de Pop.
- **Distribución:** Como se observa en la Tabla 2, ambas generan un desbalance extremo, con un clúster "basurero" que contiene más del 35-40 % de los datos, lo que impide una segmentación útil.

Cuadro 2: Distribución de tamaños de clústeres (Métricas descartadas)

Métrica	Clúster Dominante	Observación
Coseno (Average)	2446 canciones (48 %)	Superclúster genérico, incapaz de separar.
Chebyshev (Average)	1824 canciones (36 %)	Similar a Coseno, baja discriminación.

3.1.2. Análisis del Algoritmo BIRCH

El algoritmo BIRCH, a pesar de ser eficiente, mostró una **inestabilidad crítica** respecto al parámetro *threshold*.

- **Sensibilidad:** Pequeñas variaciones en el radio (de 0.37 a 0.43) provocaban cambios drásticos, fusionando clústeres coherentes en grupos gigantes sin sentido musical.
- **Prueba de Control:** Al igual que Coseno y Chebyshev, falló en la separación del registro de Rock, asignándolo al clúster mayoritario.

3.1.3. Conclusión Tarea 1.1

Tras evaluar todas las combinaciones, **seleccionamos Agglomerative Clustering con Distancia Euclídea y Enlace Ward**. Es la única configuración que garantiza:

1. **Coherencia Musical:** Separa géneros distintos (Pop vs Rock) en la prueba de control.
2. **Balance:** No genera superclústeres que absorban la mitad del dataset.
3. **Interpretabilidad:** Los centroides resultantes representan fielmente las características de las canciones.

Procederemos el resto de la práctica utilizando esta configuración.

3.2. Tarea 1.2: Análisis de Distribución y Profundidad

Se nos plantea la pregunta: **¿Es uniforme la distribución de ejemplos independientemente de la profundidad del corte?**

Para responder, generamos los dendrogramas de las tres mejores combinaciones encontradas: **Euclídea-Ward** (nuestra favorita), **Manhattan-Complete** y **Coseno-Complete**. El análisis visual de la estructura del árbol (Figura 5) nos revela comportamientos muy dispares.




Figura 5: Comparativa de estructuras jerárquicas. Nótese cómo Ward crea estructuras balanceadas frente al desequilibrio de Coseno.

3.2.1. Análisis de Uniformidad

Al realizar cortes a distintas alturas (profundidades) para evaluar el tamaño de los clústeres resultantes, observamos dos patrones claros:

1. **El patrón de Equilibrio (Ward):** En el caso de la distancia Euclídea con enlace Ward, la distribución es **relativamente uniforme** en cortes de profundidad media (distancias 3 a 6). Las ramas del dendrograma tienen longitudes similares, lo que indica que los clústeres se fusionan a ritmos parecidos, evitando la aparición de grupos dominantes prematuros.
2. **El patrón de Dominancia (Coseno y Manhattan):** Por el contrario, Coseno y Manhattan muestran una fuerte dependencia de la profundidad. A casi cualquier altura de corte, se observa un **fenómeno de absorción**: un "macro-clúster" acumula la mayoría de los ejemplos, mientras que el resto quedan fragmentados en grupos residuales (ruido). Esto confirma que métodos como **complete** o **average** son propensos al desbalance en este dataset.

3.2.2. Conclusión Tarea 1.2

Respondiendo a la pregunta inicial: **NO, la distribución no es uniforme independientemente de la profundidad.**

- La uniformidad es una propiedad dependiente del método de enlace (*linkage*). Solo los métodos de **varianza mínima (Ward)** logran mantener cierta estabilidad a distintas alturas.
- Para obtener una segmentación útil (evitando clústeres gigantes y vacíos), es imprescindible realizar el corte en una **profundidad media** (generando entre 6 y 15 clústeres) y utilizando exclusivamente el método **Ward**.

3.3. Tarea 1.3: Impacto de la Métrica en la Estructura

Nos centramos en responder: **¿Cómo afectan las diferentes métricas de distancia a la topología del dendrograma?**

Visualizamos en la Figura 6 las tres configuraciones principales. Se observa claramente cómo la definición matemática de la distancia altera el proceso de fusión.




Figura 6: Comparativa estructural. Euclídea (izq) muestra fusiones tempranas y balanceadas; Coseno y Manhattan (centro/der) muestran fusiones tardías y desbalanceadas.

3.3.1. Análisis Comparativo

El análisis de las estructuras revela tres comportamientos diferenciados:

1. **Compactación (Euclídea + Ward):** Es la única combinación que genera una estructura piramidal equilibrada. El método **ward** fuerza la fusión de grupos compactos en etapas tempranas (eje Y bajo). Al penalizar la varianza, evita que queden puntos aislados hasta el final, favoreciendo la creación de clústeres homogéneos.
2. **Dilatación y Dominancia (Coseno):** La distancia Coseno retrasa significativamente las fusiones (las ramas verticales son muy largas). Al medir similitud angular, tiende a agrupar muchos puntos en una misma "dirección" general, creando el efecto de **clúster dominante** observado anteriormente. La estructura es menos jerárquica y más "plana" hasta cortes muy altos.
3. **Resistencia a la Fusión (Manhattan):** Muestra la mayor dificultad para consolidar grupos (requiere mayor altura en el eje Y). Al usar valores absolutos (L1) en lugar de cuadrados (L2), no penaliza tanto las grandes separaciones, lo que permite que un clúster "absorba" puntos lejanos lentamente sin verse forzado a dividirse, replicando el problema de dominancia.


Conclusión: La estructura generada por **Euclídea + Ward** es la única que promete una segmentación de negocio viable, mientras que Coseno y Manhattan tienden a generar estructuras degeneradas (un grupo gigante y muchos pequeños) en este dataset.

3.4. Tarea 1.4: Índices de Calidad y Selección de K


Evaluamos la estructura de los clústeres utilizando dos métricas complementarias: **Calinski-Harabasz** (donde buscamos máximos de dispersión inter-clúster) y **Coefficiente de Silueta** (donde buscamos cohesión interna cercana a 1).

3.4.1. Análisis Comparativo de Métricas


La Figura 7 muestra la evolución de ambos índices para nuestras dos mejores configuraciones: **Euclídea-Ward** y **Manhattan-Complete**.




(a) Calinski (Ward)



(b) Calinski (Manhattan)



(c) Silueta Promedio (Ward)



(d) Silueta Promedio (Manhattan)

Figura 7: Comparativa de índices. Nótese cómo los valores de Silueta son bajos en general (≤ 0.25), indicando estructuras no convexas o solapadas.

Interpretación de Resultados:

- **Calinski-Harabasz:** Ambas métricas sugieren un número bajo de clústeres. El índice desciende suavemente, estabilizándose en el rango $K \in [7, 9]$. Esto coincide con nuestra intuición de negocio (6 géneros base + subgéneros).
- **Silueta:** Los valores son objetivamente bajos (< 0.25), lo que clasifica la estructura como "débil". Esto es esperable en datos de audio donde los géneros musicales son continuos y no hay fronteras claras. Sin embargo, **Euclídea-Ward alcanza un máximo local relativo en $K=8$** , mientras que Manhattan es más errática, sugiriendo $K=9$ o 10.

3.4.2. Análisis Visual de Siluetas (Diagramas de Sierra)

Para confirmar la estabilidad, inspeccionamos los diagramas de silueta detallados (Figura 8).



(a) Ward con $K=8$ (b) Manhattan con $K=9$

Figura 8: Detalle de cohesión por clúster. Ward $K=8$ muestra tamaños más equilibrados, mientras Manhattan $K=9$ presenta clústeres con siluetas negativas (mal asignados).

Decisión Final (Selección de K): Nos decantamos por **Euclídea-Ward con $K=8$** .

1. **Razonamiento Numérico:** Aunque la silueta es baja en todos los casos, $K=8$ en Ward maximiza la homogeneidad de tamaños (evita clústeres minúsculos) y ofrece el mejor compromiso en Calinski.
2. **Razonamiento de Negocio:** Esperamos encontrar los 6 géneros originales más posibles desgloses (ej. Pop vs Dance Pop). $K=8$ permite esa granularidad sin fragmentar excesivamente los estilos.

3.5. Tarea 1.5: Perfilado de Clústeres y Elección Final

Nos preguntan: **¿Cuál es el número óptimo de clústeres y qué representan?**

Basándonos en la estabilidad de la silueta (Tarea 1.4) y la coherencia semántica observada, seleccionamos dos candidatos finales para el perfilado:

1. **Euclídea + Ward con $K = 8$:** La configuración más equilibrada según Calinski-Harabasz.
2. **Manhattan + Complete con $K = 10$:** Una alternativa que fragmenta más los estilos, permitiendo detectar subgéneros específicos.

3.5.1. Análisis Visual de Centroides (Heatmaps)

La Figura 9 muestra las características promedio de cada grupo. Se observa cómo Ward separa claramente por **Modo** (Mayor/Menor) y **Acústica**, mientras que Manhattan aísla grupos extremos de alta energía.

	acousticness	danceability	duration_ms	energy	instrumentalness	liveness	mode	speechiness	tempo
genero									
0	0.147546	0.640408	0.486446	0.679106	0.025559	0.178233	1.0	0.083663	0.518999
1	0.725455	0.550769	0.483445	0.389331	0.024997	0.164396	1.0	0.065949	0.494780
2	0.134147	0.648069	0.489888	0.700176	0.006768	0.186470	0.0	0.091633	0.515219
3	0.160810	0.589503	0.484961	0.667989	0.672056	0.206538	0.0	0.065516	0.504018
4	0.896860	0.509759	0.427264	0.161866	0.892985	0.121013	0.0	0.064369	0.465004
5	0.683820	0.572656	0.483246	0.435232	0.035390	0.177207	0.0	0.083960	0.492384
6	0.150363	0.591008	0.485362	0.684650	0.800325	0.189387	1.0	0.069895	0.541772
7	0.888258	0.468242	0.441761	0.170553	0.881004	0.139939	1.0	0.047424	0.437976

(a) Ward ($K=8$)

	acousticness	danceability	duration_ms	energy	instrumentalness	liveness	mode	speechiness	tempo
genero									
0	0.182859	0.650568	0.490148	0.687543	0.031535	0.190240	0.0	0.090169	0.513531
1	0.888432	0.465735	0.441404	0.166169	0.832545	0.141923	1.0	0.047350	0.453836
2	0.729698	0.554379	0.483260	0.343308	0.011932	0.158289	1.0	0.059828	0.478510
3	0.845902	0.498562	0.435440	0.186987	0.855754	0.122726	0.0	0.061288	0.462514
4	0.914250	0.381750	0.309187	0.283000	0.532000	0.726250	0.0	0.242925	0.348333
5	0.193236	0.634857	0.486844	0.676113	0.012434	0.178721	1.0	0.085297	0.522897
6	0.211690	0.554836	0.489983	0.571139	0.689180	0.173850	1.0	0.063011	0.504169
7	0.083319	0.556366	0.483974	0.682354	0.812732	0.233835	0.0	0.054648	0.511024
8	0.056651	0.646592	0.475880	0.884461	0.768737	0.227829	1.0	0.082341	0.568277
9	0.740842	0.533474	0.480933	0.376525	0.016255	0.148038	0.0	0.085242	0.493006

(b) Manhattan ($K=10$)

Figura 9: Perfilado de atributos. Ward muestra una diagonal más limpia (mejor separación), mientras Manhattan detecta nichos específicos (ej. Clúster 8 de alta energía).

3.5.2. Interpretación Semántica (Mapeo a Géneros)

A continuación, asignamos una etiqueta de negocio a cada clúster basándonos en sus atributos dominantes.

Opción A: Euclídea + Ward ($K = 8$) - MODELO SELECCIONADO Este modelo captura perfectamente los 6 géneros base y añade matices emocionales (Alegre vs Triste).

Cuadro 3: Identificación de Géneros (Ward K=8)

Clúster	Género Inferido	Rasgos Distintivos
0	Pop / Rock Comercial	Alta Energía (0.67) y Danceability. Modo Mayor (Alegre).
1	Folk / Pop Acústico	Muy Acústico (0.72) y Melódico.
2	Urbano / Pop Oscuro	Similar al Pop pero en Modo Menor (Melancólico).
3	Techno / Deep House	Instrumental y Oscuro (Modo Menor).
4	Ambient Triste	Energía mínima (0.16), Instrumental y Menor.
5	Jazz / Blues	Acústico pero triste (Modo Menor).
6	Rock Instrumental / EDM	Alta Energía e Instrumentalidad (0.80). Potente.
7	Ambient Alegre	Instrumental y Acústico en Modo Mayor (Relax).

Opción B: Manhattan + Complete ($K = 10$) Aunque descartado por métricas inferiores, este modelo logró identificar un nicho interesante en el **Clúster 8 (Metal/Hardcore)** con energía máxima (0.88), que Ward diluyó entre el Rock y el Pop.

Cuadro 4: Identificación de Géneros (Manhattan K=10)

Clúster	Género Inferido	Rasgo Único
0	Pop Dance	Radiofórmula estándar.
1	Folk Puro	Máxima acústica (0.88).
2	Baladas	Acústico pero con base rítmica.
3	New Age	Instrumental de fondo.
4	Spoken Word / Podcast	Speechiness alto y Liveness extremo.
5	Pop-Rock Mainstream	Bandas comerciales.
6	Rock Instrumental	Sin voz, banda completa.
7	Techno Oscuro	Electrónica en modo menor.
8	Metal / Trance	Energía Extrema (0.88) y distorsión.
9	Jazz Melancólico	Lento y acústico.

3.5.3. Conclusión Final Tarea 1

Ambos algoritmos han superado las expectativas, identificando no solo los 6 géneros teóricos (Pop, Rock, EDM, Hip-Hop, Folk, Classical) sino también sub-géneros basados en el "Mood" (Modo Mayor/Menor).

Decisión: Nos quedamos con **Euclídea + Ward ($K = 8$)**.

- **Por Calidad:** Sus métricas de cohesión (Calinski) son superiores.
- **Por Negocio:** Genera grupos más robustos para un sistema de recomendación generalista, evitando la fragmentación excesiva de Manhattan (que separa "Pop" en 3 o 4 subgrupos difíciles de distinguir para un usuario medio).

4. Tarea II: Clustering Particional

En esta sección abordamos el problema de agrupamiento utilizando **K-Means**, uno de los algoritmos de aprendizaje no supervisado más populares. A diferencia del enfoque jerárquico, K-Means es un método particional que divide el conjunto de datos en K grupos distintos no superpuestos. Nuestro objetivo sigue siendo el mismo: identificar géneros musicales basándonos en las características de audio de las canciones.

5. Tarea 2: Algoritmos Particionales (K-Means)

Aplicamos el algoritmo K-Means, el cual particiona el dataset en K grupos minimizando la inercia (suma de distancias cuadráticas intra-clúster).

5.1. Tarea 2.1: Preprocesado

Para garantizar la comparabilidad de resultados, utilizamos el **mismo dataset preprocesado y escalado** (MinMaxScaler) empleado en el análisis jerárquico y de densidad.

5.2. Tarea 2.2 y 2.3: Selección del Número de Clústeres (K)

Ejecutamos el algoritmo para $K \in [2, 10]$ evaluando la calidad de la partición mediante cuatro métricas: Inercia (Codo), Silueta, Calinski-Harabasz y Davies-Bouldin.




Figura 10: Evolución de métricas. Se observa un conflicto entre el óptimo matemático y el de negocio.

5.2.1. Decisión: Matemáticas vs. Negocio

Al analizar la Figura 10, nos enfrentamos a una disyuntiva:

- **El Óptimo Matemático ($K = 3$):** Maximiza la Silueta ($\approx 0,45$) y minimiza Davies-Bouldin. Sin embargo, una solución de 3 grupos es **insuficiente** para la riqueza musical del problema (mezclaría Rock, Pop y Hip-Hop en un solo saco).
- **El Óptimo de Negocio ($K = 8$):** Dado que el enunciado exige buscar al menos 6 géneros, observamos el rango $K \geq 6$. En $K = 8$ encontramos un pico local de recuperación en la Silueta y un mínimo local en Davies-Bouldin.

Selección: Elegimos $K = 8$ como el punto de equilibrio que respeta la restricción de dominio sin sacrificar excesiva calidad matemática.

5.3. Tarea 2.4: Interpretación de los Clústeres ($K = 8$)

La Figura 11 muestra los centroides finales del modelo. Basándonos en estos perfiles promedio, etiquetamos cada grupo.




Figura 11: Perfilado de los 8 clústeres generados por K-Means.

Cuadro 5: Caracterización de Géneros (K-Means $K = 8$)

Clúster	Etiqueta Inferida	Rasgos Dominantes
0	Classical	Acousticness e Instrumentalness muy altos. Energía baja.
1	Hip-Hop / Rap	Alta Energía y Danceability. Tonalidad Menor.
2	Pop Comercial	Muy bailable y energético. Tonalidad Mayor (Alegre).
3	Soundtrack / Ambient	Instrumental y tranquilo (como Classical) pero en Tonalidad Menor.
4	Acoustic / Folk	Alta Acústica pero con Voz (Instrumentalness nulo). Energía media.
5	Rock / Indie	Acústico-Vocal con energía media y Tonalidad Menor.
6	Electronic / EDM	Energía máxima y sonidos sintéticos (Instrumental).
7	Dance-Pop	Similar a EDM pero en Tonalidad Mayor (más comercial/luminoso).

5.4. Tarea 2.5: Comparativa Final (Particional vs Jerárquico)

Contrastamos el desempeño de K-Means frente al Clustering Jerárquico (Ward) analizado en la Tarea 1.

Cuadro 6: Comparativa Técnica y Funcional

Aspecto	K-Means (Particional)	Jerárquico (Aglomerativo)
Geometría	Asume formas esféricas (globulares).	Flexible (especialmente con enlaces como <i>Single</i> , aunque Ward también busca esferas).
Eficiencia	Muy rápido y ligero ($O(n \cdot K \cdot i)$). Escalable.	Muy costoso ($O(n^2)$). Difícil con muchos datos.
Resultados	Sensible a la inicialización (requiere <code>n_init</code>).	Determinista (siempre da el mismo resultado).
Visión	"Foto fija" de una partición concreta.	Estructura completa (Dendrograma) multinivel.

Conclusión: Ambos algoritmos convergen en que la estructura óptima ronda los **8 clústeres**, validando la robustez de los géneros encontrados. K-Means destaca por su rapidez para uso en producción, mientras que el Jerárquico nos aportó mayor interpretabilidad inicial.

6. Tarea III: Clústering de densidad

Procedemos a realizar las tareas

6.1. Tarea 3.1: Preprocesamiento para Densidad

Nos piden: “Realiza el pre-procesamiento necesario para poder aplicar algoritmos de densidad.”

Partimos del dataset generado en la Tarea 0, manteniendo el escalado **MinMaxScaler**. Dado que DBSCAN define los clústeres mediante vecindades esféricas de radio ϵ , es crítico que todas las variables tengan el mismo rango $[0, 1]$ para que ninguna domine el cálculo de distancia.

Como ajuste específico para este algoritmo, **eliminamos la variable mode**.

- **Justificación:** Al ser una variable binaria (0 o 1), introduce saltos discretos en el espacio euclídeo. Esto puede provocar que DBSCAN separe artificialmente grupos solo por su tonalidad (Mayor/Menor) en lugar de por su densidad real, o que distorsione el cálculo de vecinos cercanos (k -NN).

El resto de variables continuas (*danceability*, *energy*, etc.) se mantienen intactas.

6.2. Tarea 3.2: Selección de Parámetros (Eps y MinPts)

Nos piden establecer los valores iniciales para el radio (**eps**) y la densidad mínima (**min_samples**).

6.2.1. Estimación de MinPts

Para determinar el número mínimo de puntos, evaluamos dos heurísticas estándar en la literatura:

- **Criterio Dimensional ($2 \cdot D$):** Dado que nuestro dataset tiene 8 dimensiones tras el preprocesado, obtenemos un valor de **16**. Este umbral suele ser robusto frente al ruido.
- **Criterio Logarítmico ($\ln(N)$):** Para nuestros ≈ 4700 registros, el cálculo arroja un valor de **8**. Este umbral es más flexible y permite detectar clústeres más pequeños.

Probaremos ambos valores (8 y 16) como referencia para el análisis de densidad.

6.2.2. Estimación de Eps (K-Distance Plot)

Utilizamos el gráfico de distancias al k -ésimo vecino (K-Distance Plot) para encontrar el “codo” de la curva, que indica el umbral de distancia donde los puntos dejan de ser considerados vecinos densos y pasan a ser ruido.




Figura 12: Curvas K-Distance para $K=8$ y $K=16$. Se observan puntos de inflexión (codos) suaves.

Análisis de la Gráfica: Como se observa en la Figura 12, las curvas para $k = 8$ y $k = 16$ son muy similares, mostrando puntos de inflexión en un rango estrecho:

- Para $k = 8$ (línea inferior), el codo se sitúa aprox. en $\epsilon \approx 0,22$.
- Para $k = 16$ (línea superior), el codo sube ligeramente a $\epsilon \approx 0,25$.

Conclusión Tarea 3.2: Definimos nuestro espacio de búsqueda inicial probando combinaciones con **MinPts** $\in \{8, 16\}$ y un rango de $\epsilon \in [0,22, 0,26]$, aunque realizaremos un barrido más amplio en la siguiente tarea para asegurar la estabilidad.

6.3. Tarea 3.3: Evaluación de Calidad y Variación de Parámetros

Nos preguntan: ¿Cómo varía la calidad del clustering al modificar `eps` y `min_samples`?

Para responder, ejecutamos un barrido experimental con las combinaciones seleccionadas en la tarea anterior. La Tabla 7 resume el impacto de los hiperparámetros en la estructura descubierta.

Cuadro 7: Comparativa de configuraciones DBSCAN (Total muestras ≈ 4765)

MinPts	Epsilon (ϵ)	Nº Clústers	Ruido (Outliers)	Evaluación
8	0.2524	3	2117 (44 %)	Pocos grupos, ruido moderado.
8	0.2207	7	2795 (59 %)	Mejor granularidad (Pop, Folk, Dance..)
16	0.2524	2	2735 (57 %)	Demasiado genérico (solo 2 polos).
16	0.2207	3	3713 (78 %)	Excesivamente restrictivo (casi todo ruido).

6.3.1. Análisis de la Variación

1. **Sensibilidad a MinPts:** Aumentar MinPts de 8 a 16 es devastador para este dataset. La proporción de ruido se dispara hasta el 78 %, lo que indica que las "islas" de densidad musical son pequeñas y no soportan requisitos de densidad tan altos.
2. **Sensibilidad a Eps:** Reducir ligeramente ϵ (de 0.25 a 0.22) fragmenta los grandes bloques en clústers más específicos, pasando de 3 a 7 grupos. Esto es positivo, ya que permite distinguir matices (ej. Pop Dance vs Pop Suave).

6.3.2. Análisis de la Mejor Configuración ($\epsilon = 0,22$, $Min = 8$)

A pesar de descartar casi el 60 % de los datos como ruido (algo habitual en DBSCAN con datos de alta dimensionalidad real), esta configuración es la única que revela una estructura rica. La Figura 13 muestra los perfiles de los 7 clústers encontrados.

	acousticness	danceability	duration_ms	energy	instrumentalness	liveness	speechiness	tempo
cluster								
-1	0.394666	0.578372	0.479648	0.550839	0.218247	0.205573	0.097166	0.514698
0	0.274889	0.642074	0.489233	0.615082	0.002457	0.131550	0.052187	0.496969
1	0.991111	0.696111	0.305475	0.018401	0.959815	0.108489	0.074081	0.366718
2	0.937296	0.605986	0.439171	0.123832	0.914296	0.105823	0.041311	0.469368
3	0.983706	0.332176	0.440572	0.030595	0.930353	0.086912	0.044788	0.296942
4	0.966600	0.113450	0.461910	0.020091	0.892200	0.098080	0.041820	0.316684
5	0.312286	0.677000	0.462423	0.664714	0.000226	0.113743	0.055557	0.682132
6	0.147800	0.747857	0.491711	0.674286	0.000127	0.396714	0.037743	0.500394

Figura 13: Perfiles de los 7 clústers hallados con $\epsilon = 0,22$, $MinPts = 8$. Se aprecian perfiles muy puros: Clúster 1 (Ambiental), Clúster 6 (Muy Rítmico), Clúster 3 (Baladas).

Interpretación de los Grupos: DBSCAN ha actuado como un "detector de arquetipos puros", ignorando las canciones de transición:

- **Polos Opuestos:** Separa perfectamente lo **Acústico/Ambiental** (Clúster 1, 4) de lo **Energético/Dance** (Clúster 5, 6).
- **Matices:** Distingue entre *Folk con ritmo* (Clúster 2) y *Baladas lentas* (Clúster 3).

Conclusión: Aunque la cobertura de datos es baja (mucho ruido), la pureza de los clústers encontrados es alta. Nos quedamos con esta configuración para la evaluación final.

6.4. Tarea 3.4: Evaluación de Índices de Calidad

Evaluamos la calidad de las dos configuraciones candidatas utilizando **Davies-Bouldin** (robusto para separación) y **Silueta** (cohesión). La Tabla 8 resume los resultados.

Cuadro 8: Comparativa de Índices de Calidad para DBSCAN

Configuración	Nº Clústers	Davies-Bouldin	Silueta	Interpretación Matemática
Eps=0.25, Min=16	2	0.39 (Excel.)	0.59 (Buena)	Estructura muy sólida.
Eps=0.22, Min=8	7	1.35 (Acept.)	-0.17 (Mala)	Estructura débil/ruidosa.


6.4.1. La Paradoja Calidad-Utilidad

Nos encontramos ante un compromiso clásico en clustering:

- **La Victoria Matemática (2 Clústers):** La configuración con $MinPts = 16$ obtiene índices excelentes (Silueta 0.59). Sin embargo, es un resultado **trivial**: solo separa "Pop Comercial" de "Folk Acústico". Decir que en el mundo solo existen dos géneros musicales es inútil para un sistema de recomendación.
- **La Utilidad Semántica (7 Clústers):** La configuración con $MinPts = 8$ tiene una Silueta negativa (-0.17). Esto se debe a que DBSCAN genera formas no convexas y clasifica mucho ruido, lo que penaliza fuertemente este índice (diseñado para clústeres esféricos sin ruido). A pesar de la "mala nota", esta partición es la única que distingue matices valiosos (Baladas, Ambient, Dance).

6.4.2. Análisis Visual de Siluetas

Los diagramas de silueta (Figura 14) confirman el diagnóstico.



(a) Eps=0.25 (2 Clústers). Bloques sólidos y positivos.

(b) Eps=0.22 (7 Clústers). Muchas barras negativas debido al ruido y formas irregulares.

Figura 14: Comparativa de cohesión. El modelo de 7 clústeres sufre penalización por la alta cantidad de puntos fronterizos (ruido).

Conclusión Tarea 3.4: Matemáticamente, DBSCAN prefiere simplificar el problema a 2 grandes grupos. Sin embargo, priorizaremos la **utilidad de negocio** de la partición de 7 clústeres, aceptando que sus métricas de calidad son inferiores debido a las limitaciones del índice Silueta frente al ruido.

6.5. Tarea 3.5: Elección del Número Óptimo y Perfilado

Nos enfrentamos a la decisión final: ¿Elegimos la solidez matemática (2 clústers) o la utilidad práctica (7 clústers)?

6.5.1. Análisis Comparativo de Perfiles

La Figura 15 contrasta la riqueza de información de ambas soluciones.

	acousticness	danceability	duration_ms	energy	instrumentalness	liveness	speechiness	tempo
cluster								
-1	0.394666	0.578372	0.479648	0.550839	0.218247	0.205573	0.097166	0.514698
0	0.274889	0.642074	0.489233	0.615082	0.002457	0.131550	0.052187	0.496969
1	0.991111	0.696111	0.305475	0.018401	0.959815	0.108489	0.074081	0.366718
2	0.937296	0.605986	0.439171	0.123832	0.914296	0.105823	0.041311	0.469368
3	0.983706	0.332176	0.440572	0.030595	0.930353	0.086912	0.044788	0.296942
4	0.966600	0.113450	0.461910	0.020091	0.892200	0.098080	0.041620	0.316684
5	0.312286	0.677000	0.462423	0.664714	0.000226	0.113743	0.055557	0.682132
6	0.147800	0.747857	0.491711	0.674286	0.000127	0.396714	0.037743	0.500394

(a) Solución $MinPts = 16$ (2 Clústers). Visión binaria (Pop vs Folk).

(b) Solución $MinPts = 8$ (7 Clústers). Visión rica en matices.

Figura 15: Mientras la solución de 2 clústers simplifica el problema al extremo, la de 7 clústers revela la estructura interna de los subgéneros.

6.5.2. Interpretación Semántica (Modelo de 7 Clústers)

Descartamos la solución de 2 clústers por ser trivial (solo distingue "Música Comercial" de "Música Acústica"). Nos centramos en perfilar la solución de **7 Clústers**, que ha demostrado capturar gran parte de los géneros base del problema.

Cuadro 9: Identificación de Géneros (DBSCAN con 7 Clústers)

Clúster	Género Inferido	Rasgos Distintivos
-1	<i>Ruido / Transición</i>	Canciones híbridas que no alcanzan la densidad crítica.
0	Pop / Dance	Comercial, alta energía y nula instrumentalidad.
1	Folk Puro	Acústico extremo (0.99) y energía mínima.
2	Indie / Pop Acústico	Acústico (0.93) pero con base rítmica (Danceability 0.60).
3	Ambient / New Age	Instrumental, lento y relajante (Energía 0.03).
4	Hip-Hop / Rap	Destaca por su <i>Speechiness</i> y energía contenida.
5	Pop-Rock Mainstream	Energía alta y sonido de banda.
6	Rock Alt. / Indie Rock	Máxima intensidad y presencia de directo (<i>Liveness</i>).

Validación de Géneros: DBSCAN ha logrado recuperar con éxito 4 de los 6 géneros objetivo: **Pop, Folk, Rock y Hip-Hop**. Además, ha descubierto un género latente no etiquetado explícitamente: el **Ambient/New Age** (Clúster 3).

6.5.3. Conclusión Final

El número óptimo es **7 Clústers** (obtenido con $\epsilon = 0,22$, $MinPts = 8$).

Justificación: Aunque la solución de 2 clústers tiene mejores métricas de Silueta (por la ausencia de solapamiento), es inútil para un sistema de recomendación real. Preferimos la solución de 7 clústers porque, a pesar de clasificar mucho ruido (Clúster -1), los grupos que detecta son **puros, coherentes y cubren la diversidad musical** del dataset.